

第二言語学習者の単語習熟度の変化を考慮した誤り予測

Toward Learner Error Prediction based on Progression of L2 Vocabulary Proficiency

村上 彰悟 *1

Shogo Murakami

杉山 誠治 *1

Seiji Sugiyama

梶原 智之 *1*2

Tomoyuki Kajiwar

荒瀬 由紀 *3

Yuki Arase

*1愛媛大学

Ehime University

*2大阪大学

The University of Osaka

*3東京科学大学

Institute of Science Tokyo

本研究では、翻訳や聞き取りなどの第二言語学習において、学習者が文中のどの単語を誤るかを推定する誤り予測に取り組む。先行研究では、複数の学習者による学習履歴を単一モデルで扱うため、各学習者の単語習熟度はモデル内部で暗黙的に処理されてきた。一方で我々は、各学習者の知識状態を問題に回答するたびに推定および更新する Knowledge Tracing の技術を用いて、各学習者の単語習熟度を明示的に扱い、誤り予測に活用する。英語・スペイン語・フランス語における評価実験の結果、提案手法の有効性を確認できた。

1. はじめに

学習履歴を分析し、学習者が将来誤る可能性のある問題を予測するタスクが長年研究 [Corbett 95, Piech 15, Shen 24] されている。近年では、オンラインでの学習の普及により、学習履歴をデータとして記録することが容易になってきたため、大規模データに基づく検証が進んでいる。Second Language Acquisition Modeling (SLAM) [Settles 18]*1 は、特定の第二言語学習者が将来どの単語を誤るかを予測するタスクであり、本研究ではこのタスクに取り組む。

図 1 に示すように、SLAM では、ある問題における正解文中の各単語について、学習者が正解するか不正解するかを二値分類する。ここでの正解文は、複数の正解候補文から学習者の回答文と最も類似する文が選択される。このタスクで扱う問題形式として、(1) reverse_translate: 第一言語の文が与えられ、第二言語の翻訳文を記述する、(2) reverse_tap: 第一言語の文が与えられ、語群を並び替えて第二言語の翻訳文を完成させる、(3) listen: 第二言語の文を聞いて文字起こしする、の 3 種類がある。これらの問題とともに、ユーザ ID や問題形式、回答に要した時間などのメタ情報が提供される。

本タスクにおける先行研究では、単語とメタ情報を決定木などの機械学習モデルに単純に与える手法 [Chen 18, Rich 18] や、単語とメタ情報の埋め込みを Long Short-Term Memory (LSTM) モデルに与える手法 [Kaneko 18, Yuan 18], LSTM から得た単語情報と Multi-Layer Perceptron (MLP) から得たメタ情報を統合する手法 [Xu 18, Hu 19] などが提案されている。しかし、これらの先行研究では、各学習者の特定単語に関する習熟度が明示的に考慮されていない。学習者が単語を正しく想起できる確率は、その単語に対する過去の正誤や経過時間に応じて変化する [Settles 16] が、先行研究ではこれらの情報がモデル内部で暗黙的に処理されている。そのため、各学習者の特定単語に関する習熟度は、他の特徴量と混在したまま扱われ、誤り予測に充分反映されていない可能性がある。

本研究では、第二言語学習者の誤り予測を改善するために、単語情報とメタ情報を統合して扱う既存手法 [Xu 18, Hu 19, J. Jiménez Palenzuela 22] をベースに、新たに Knowledge Tracing (KT) [Corbett 95] の技術を導入し、各学習者の単語習熟度を明示的に推定および更新する手法を提案する。KT




図 1: Second Language Acquisition Modeling タスクの概要

は学習履歴に基づいて各学習者の知識状態を推定および更新する技術であり、本研究では注意機構によって学習履歴の影響を柔軟に考慮できる Transformer [Vaswani 17] ベースの KT モデルを訓練し、単語習熟度に相当する表現を得る。評価実験の結果、単語習熟度を明示的に追加することで性能が改善し、提案手法の有効性を確認できた。

2. 関連研究

学習支援の分野では、問題に回答するたびに学習者の知識状態が変化することを考慮して、ある時点でどの知識をどの程度獲得しているかという学習者の知識状態を推定し、将来の正誤予測に活用する Knowledge Tracing (KT) [Corbett 95] が研究されている。KT は、問題と正誤ラベルの系列から学習者の知識状態を更新し、次の問題に誤答する確率を予測する枠組みである。時刻 t で提示される問題を q_t 、その正誤を $r_t \in \{0, 1\}$ 、学習履歴を $\{(q_t, r_t)\}_{t=1}^T$ として表す。KT モデルは、履歴に基づく知識状態 $\mathbf{h}_t$ を逐次的に更新し、次時刻で提示される問題 q_{t+1} に対する誤答確率 $\hat{p}_{t+1}$ を推定する。すなわち、

$$\mathbf{h}_t = f(\mathbf{h}_{t-1}, q_t, r_t) \quad (1)$$

$$\hat{p}_{t+1} = P(r_{t+1} = 1 \mid \mathbf{h}_t, q_{t+1}) \quad (2)$$

と定式化できる。代表的な KT モデルとして、式 (1) の $f(\cdot)$ を LSTM で実装した Deep Knowledge Tracing (DKT) [Piech 15] や、Transformer で実装した Attentive Knowledge Tracing (AKT) [Ghosh 20] などが挙げられる。本研究では、これらの Knowledge Tracing の技術を用いて各学習者の単語習熟度を考慮し、SLAM タスクの性能を改善する。

連絡先: 村上彰悟 (愛媛大学) murakami@ai.cs.ehime-u.ac.jp

*1 <https://sharedtask.duolingo.com/2018.html>




図 2: 提案手法：単語習熟度を表現する KT，単語情報を表現する単語エンコーダ，メタ情報を表現する MLP を統合した誤り予測

3. 提案手法

本研究では，SLAM タスクの性能改善のために，単語情報とメタ情報に加えて，学習者の単語習熟度を考慮する誤り予測モデルを提案する．提案手法の概要を図 2 に示す．左から順に，単語習熟度を表現する Knowledge Tracing，単語情報を表現する単語エンコーダ，メタ情報を表現する MLP であり，これらの 3 つの情報を統合して学習者の誤りを推定する．

3.1 単語習熟度の表現

学習者の単語習熟度を推定および更新する KT モデルとして，本研究では AKT [Ghosh 20] を用いる．対象単語に関する当該学習者の正誤履歴を系列として AKT へ入力し，現在の単語習熟度に相当する表現を得る．

問題定義 一般的な KT では，学習者が解く 1 つの問題に対して正誤ラベルが 1 つ与えられ，その問題 ID と正誤の系列から次の正答確率を推定する．一方で，本研究で扱う SLAM タスクでは，1 つの問題は複数の単語から構成され，それらの各単語に対して正誤ラベルが付く．そのため，本研究における誤り予測の単位は，問題ではなく，問題内の各単語である．

履歴の制限 q_t として単語を用いる場合，一般的な KT よりも学習履歴が長くなりやすく，計算量が課題となる．そこで本研究では，学習履歴を直近の W 件のみに制限して使用する．予測対象の単語 q_i に一致する学習履歴を W 件抽出し，その系列を AKT へ入力する．これにより，計算量を抑えつつ，対象単語に関する学習履歴を効果的に考慮できる．

問題形式による区別 図 1 に示したように，本タスクには 3 種類の問題形式が含まれる．そして，表 1 に示すように，問題形式ごとに学習者の正解率には大きな差がある．これは，同一単語であっても，問題形式によって正答しやすさが異なることを示唆している．そこで本研究では， q_t を単語と問題形式の組み合わせによって（単語 ID，問題形式）の形で表現する．

単語習熟度の表現 ある単語 q_i に関する学習履歴を系列として AKT へ入力し，式 (1) によって，各時刻 t で単語習熟度に対応する隠れ表現 $\mathbf{h}_t$ を更新する．また，式 (2) および $\mathbf{h}_t$ に基づき，時刻 $t+1$ におけるその単語の誤答確率 $\hat{p}_{t+1}$ も推定する．そして，学習履歴の系列末尾から得られる $\mathbf{h}_T$ が現在の単語習熟度であると考え， $\hat{p}_{T+1}$ とともに MLP_{KT} へ入力し，単語習熟度の表現 $\mathbf{r}^{\text{KT}}$ を得る．

$$\mathbf{r}^{\text{KT}} = \text{MLP}_{\text{KT}}([\mathbf{h}_T, \hat{p}_{T+1}]) \quad (3)$$

表 1: 問題形式ごとの学習者の平均正解率

問題形式	正解率
reverse_translate	0.79
reverse_tap	0.92
listen	0.76

3.2 単語情報の表現

単語情報の表現には，単語エンコーダとして，LSTM や Transformer または事前訓練済みの多言語マスク言語モデル [Conneau 20] を用いる．reverse_translate 形式および reverse_tap 形式では，第一言語の問題文が提供されているため，問題文と正解文を特殊トークン ([SEP]) で連結して単語エンコーダへ入力する．ただし，listen 形式では，問題文が提供されないため，正解文のみを単語エンコーダへ入力する．

まず，入力系列 $\mathbf{x}$ を単語エンコーダ $\text{Encoder}(\cdot)$ へ入力し，正解文中の i 番目の単語に対する最終層のベクトル $\mathbf{h}_i$ を得る．

$$\mathbf{h}_i = \text{Encoder}(\mathbf{x})_i \quad (4)$$

次に，単語エンコーダから得られた単語ベクトル $\mathbf{h}_i$ を $\text{MLP}_{\text{token}}$ へ入力し，単語の表現 $\mathbf{r}_i^{\text{token}}$ を得る．

$$\mathbf{r}_i^{\text{token}} = \text{MLP}_{\text{token}}(\mathbf{h}_i) \quad (5)$$

3.3 メタ情報の表現

本研究では，SLAM タスクで提供される全てのメタ情報を用いる．これらを，学習者に関するメタ情報と問題に関するメタ情報の 2 種類に分けて使用する．

学習者に関するメタ情報

- user：ユーザ ID
- countries：居住国の ISO 国コード
- days：学習開始からの経過日数

問題に関するメタ情報

- format：問題形式 (reverse_translate/reverse_tap/listen)
- time：回答に要した時間

- **prompt**: 学習者に与えられる問題文 (reverse_translate および reverse_tap の形式のみ付与される)
- **client**: 利用端末種別 (android/ios/web)
- **session**: セッション種別 (lesson/practice/test)

まず, 学習可能な埋め込み層によって変換したカテゴリ特徴量のベクトルおよび数値特徴量のスカラーを $x^{(\cdot)}$ とし, それらを連結して学習者に関する入力ベクトル $\mathbf{u}$ および問題に関する入力ベクトル $\mathbf{v}$ を作る.

$$\mathbf{u} = [x^{\text{user}}, x^{\text{country}}, x^{\text{days}}], \mathbf{v} = [x^{\text{client}}, x^{\text{session}}, x^{\text{format}}, x^{\text{time}}] \quad (6)$$

次に, $\mathbf{u}$ を MLP_{user} に入力して学習者に関する表現 $\mathbf{r}^{\text{user}}$ を得る. また, $\mathbf{v}$ を $\text{MLP}_{\text{exercise}}$ に入力して問題に関する表現 $\mathbf{r}^{\text{exercise}}$ を得る.

$$\mathbf{r}^{\text{user}} = \text{MLP}_{\text{user}}(\mathbf{u}), \quad \mathbf{r}^{\text{exercise}} = \text{MLP}_{\text{exercise}}(\mathbf{v}) \quad (7)$$

最後に, $\mathbf{r}^{\text{user}}$ と $\mathbf{r}^{\text{exercise}}$ の要素積 $\mathbf{r}^{\text{user}} \odot \mathbf{r}^{\text{exercise}}$ を MLP_{meta} に入力してメタ表現 $\mathbf{r}^{\text{meta}}$ を得る.

$$\mathbf{r}^{\text{meta}} = \text{MLP}_{\text{meta}}(\mathbf{r}^{\text{user}} \odot \mathbf{r}^{\text{exercise}}) \quad (8)$$

3.4 誤り予測

単語習熟度の表現 $\mathbf{r}^{\text{KT}}$, 単語情報の表現 $\mathbf{r}_i^{\text{token}}$, メタ情報の表現 $\mathbf{r}^{\text{meta}}$ を統合したベクトル $\mathbf{r}_i^{\text{all}}$ を MLP_{pred} に入力し, 以下のように単語 q_i に対する誤答確率 $\hat{p}_i$ を推定する.

$$\mathbf{r}_i^{\text{all}} = \mathbf{r}^{\text{KT}} + (\mathbf{r}_i^{\text{token}} \odot \mathbf{r}^{\text{meta}}) \quad (9)$$

$$p_i = \text{MLP}_{\text{pred}}(\mathbf{r}_i^{\text{all}}) \quad (10)$$

ここで, 統合ベクトル $\mathbf{r}_i^{\text{all}}$ については, 加算と要素積による複数の統合パターンを比較した予備実験の結果, 最も高い性能を示した式 (9) の形式を採用した.

4. 評価実験

4.1 実験設定

データ SLAM タスク [Settles 18] において公開されている学習履歴データ^{*2}を用いた. これは, 言語学習アプリ Duolingo^{*3} における実際の学習履歴データであり, 全 6,449 人のユーザに対する学習開始から 30 日間のログが収録されている. SLAM データセットは 3 つの言語トラックで構成されており, それらは, スペイン語を第一言語とするユーザの英語学習履歴 (Es → En), 英語を第一言語とするユーザのスペイン語学習履歴 (En → Es), 英語を第一言語とするユーザのフランス語学習履歴 (En → Fr) である. 公式の分割に従い, 各ユーザの学習履歴を時系列順に並べ, 先頭 80% を訓練データ, 続く 10% を検証データ, 最後の 10% を評価データとして実験した. 表 2 に, データセットの統計情報を示す.

評価 SLAM タスクにおける公式の評価方法に従い, AUC および F1 スコアを用いて誤り予測モデルの性能を自動評価した. 実験には, 以下に示す複数の単語エンコーダを採用し, KT に基づく単語習熟度の有無を比較することによって, 提案手法の有効性を検証した.

*2 <https://dataverse.harvard.edu/dataset.xhtml?persistentId=doi:10.7910/DVN/8SWHNO>

*3 <https://ja.duolingo.com/>

表 2: SLAM データセットの統計情報

L1 → L2		Es → En	En → Es	En → Fr
学習用	単語数	2.6M	2.0M	927k
	問題数	824k	731k	326k
	誤り率	13%	14%	16%
検証用	単語数	387k	289k	138k
	問題数	115k	96k	43k
	誤り率	14%	16%	18%
評価用	単語数	387k	282k	136k
	問題数	114k	93k	41k
	誤り率	15%	16%	18%
ユーザ数		2,593	2,643	1,213
1 問題あたりの語数		3.18	2.70	2.84
ユニーク単語数		2,226	2,915	2,178

モデル KT モデルには AKT [Ghosh 20] を用い, 対象とする学習履歴は $W = 100$ に設定した. 単語エンコーダとして, 双方向 LSTM (BiLSTM), 事前訓練なしの Transformer, マスク言語モデル BERT [Devlin 19] の多言語版である mBERT^{*4}, 多言語マスク言語モデルの XLM-RoBERTa [Conneau 20]^{*5}, マスク言語モデル DeBERTa [He 21] の多言語版である mDeBERTa^{*6}, マスク言語モデル ModernBERT [Warner 25] の多言語版である mmBERT [Marone 25]^{*7} を用いた.

訓練 先行研究 [J. Jiménez Palenzuela 22] に従い, 図 2 の提案手法を 3 段階で訓練した. 第 1 段階として, KT モデルのみを訓練した. 第 2 段階として, KT モデルと単語エンコーダのパラメータを固定し, 6 つの MLP およびカテゴリ特徴量の埋め込み層を訓練した. 第 3 段階として, KT モデルのパラメータを固定したまま, 単語エンコーダ, MLP および埋め込み層を訓練した. 最適化には AdamW [Loshchilov 17] を用い, 学習率は AKT を 1×10^{-5} , MLP および埋め込み層を 3×10^{-4} , 単語エンコーダを 1×10^{-5} に設定した. バッチサイズは 256 とし, 検証データにおける損失が 3 回改善されなくなるまで訓練を続ける Early Stopping を適用した.

4.2 実験結果

表 3 に実験結果を示す. 単語エンコーダの種類および単語習熟度の有無の両方が, 性能に寄与していることが確認できる.

まず, 単語エンコーダの違いに着目すると, BiLSTM や Transformer と比較して, 事前訓練済みのマスク言語モデルを用いた場合に性能が改善した. mBERT などのマスク言語モデルを用いることで, 事前訓練で獲得した言語知識を反映できるため, 期待通りに性能が改善したと考えられる.

次に, 単語習熟度の考慮による性能の変化を比較する. 一部の単語エンコーダと言語トラックの組み合わせにおいては改善幅が限定的であるものの, 多くの実験設定において性能 (特に F1 スコア) が向上した. 特に, mBERT などのマスク言語モデルを用いた場合に, 提案手法によって大きな性能改善が見られた. これらの実験結果から, マスク言語モデルによる優れた単語表現に加えて, 各学習者の対象単語に関する学習履歴の反映が, より精緻な誤り予測に貢献することを確認できた.

*4 <https://huggingface.co/google-bert/bert-base-multilingual-uncased>

*5 <https://huggingface.co/FacebookAI/xlm-roberta-base>

*6 <https://huggingface.co/microsoft/mdeberta-v3-base>

*7 <https://huggingface.co/jhu-clsp/mmBERT-base>

表 3: 実験結果

単語エンコーダ	単語習熟度	Es → En		En → Es		En → Fr		Average	
		AUC	F1	AUC	F1	AUC	F1	AUC	F1
BiLSTM	✓	0.844	0.490	0.811	0.466	0.835	0.509	0.830	0.488
		0.844	0.491	0.813	0.472	0.831	0.517	0.829	0.493
Transformer	✓	0.846	0.490	0.814	0.474	0.835	0.496	0.831	0.487
		0.845	0.485	0.808	0.463	0.836	0.515	0.830	0.488
mBERT	✓	0.848	0.483	0.819	0.463	0.840	0.504	0.836	0.483
		0.851	0.505	0.820	0.481	0.842	0.518	0.838	0.501
XLM-RoBERTa	✓	0.849	0.489	0.819	0.481	0.841	0.522	0.836	0.497
		0.851	0.500	0.821	0.480	0.839	0.523	0.837	0.501
mDeBERTa	✓	0.850	0.489	0.818	0.469	0.840	0.516	0.836	0.491
		0.851	0.502	0.819	0.478	0.841	0.529	0.837	0.503
mmBERT	✓	0.850	0.487	0.820	0.476	0.842	0.516	0.837	0.493
		0.851	0.503	0.820	0.480	0.842	0.530	0.838	0.504

5. おわりに

本研究では、第二言語学習者が将来どの単語を誤るかを予測する Second Language Acquisition Modeling タスクに取り組んだ。提案手法では、学習者の単語習熟度を Knowledge Tracing の技術によって推定し、誤り予測に活用した。評価実験の結果、学習者の単語習熟度を考慮することによって、多くのマスク言語モデルにおいて誤り予測の性能が向上し、提案手法の有効性を確認できた。

今後の課題として、単語習熟度の推定や誤り予測のために必要な学習履歴データの小規模化が挙げられる。少量の学習履歴から将来の誤り傾向を推定できれば、効果的な学習支援を実現していける可能性がある。

謝辞

本研究はJSPS 科研費（基盤研究 B，課題番号:JP25K03233）の助成を受けたものです。

参考文献

- [Chen 18] Chen, G., Hauff, C., and Houben, G.-J.: Feature Engineering for Second Language Acquisition Modeling, in *Proc. of BEA*, pp. 356–364 (2018)
- [Conneau 20] Conneau, A., Khandelwal, K., Goyal, N., Chaudhary, V., Wenzek, G., Guzmán, F., Grave, E., Ott, M., Zettlemoyer, L., and Stoyanov, V.: Unsupervised Cross-lingual Representation Learning at Scale, in *Proc. of ACL*, pp. 8440–8451 (2020)
- [Corbett 95] Corbett, A. T. and Anderson, J. R.: Knowledge tracing: Modeling the acquisition of procedural knowledge, *User Modeling and User-Adapted Interaction*, Vol. 4, No. 4, pp. 253–278 (1995)
- [Devlin 19] Devlin, J., Chang, M.-W., Lee, K., and Toutanova, K.: BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding, in *Proc. of NAACL*, pp. 4171–4186 (2019)
- [Ghosh 20] Ghosh, A., Heffernan, N. T., and Lan, A. S.: Context-Aware Attentive Knowledge Tracing, in *Proc. of KDD*, pp. 2330–2339 (2020)
- [He 21] He, P., Gao, J., and Chen, W.: DeBERTaV3: Improving DeBERTa using ELECTRA-Style Pre-Training with Gradient-Disentangled Embedding Sharing, *arXiv:2111.09543* (2021)
- [Hu 19] Hu, Y., Huang, H., Lan, T., Wei, X., Nie, Y., Qi, J., Yang, L., and Mao, X.: Multi-task Learning for Low-Resource Second Language Acquisition Modeling, *arXiv:1908.09283* (2019)
- [J. Jiménez Palenzuela 22] J. Jiménez Palenzuela, Álvaro, Frasin-car, F., and Truşcă, M. M.: Modeling Second Language Acquisition with Pre-trained Neural Language Models, *Expert Systems with Applications*, Vol. 207, (2022)
- [Kaneko 18] Kaneko, M., Kajiwara, T., and Komachi, M.: TMU System for SLAM-2018, in *Proc. of BEA*, pp. 365–369 (2018)
- [Loshchilov 17] Loshchilov, I. and Hutter, F.: Fixing Weight Decay Regularization in Adam, *arXiv:1711.05101* (2017)
- [Marone 25] Marone, M., Weller, O., Fleshman, W., Yang, E., Lawrie, D. J., and Durme, B. V.: mmBERT: A Modern Multilingual Encoder with Annealed Language Learning, *arXiv:2509.06888* (2025)
- [Piech 15] Piech, C., Bassen, J., Huang, J., Ganguli, S., Sahami, M., Guibas, L. J., and Sohl-Dickstein, J.: Deep Knowledge Tracing, in *Proc. of NeurIPS*, pp. 505–513 (2015)
- [Rich 18] Rich, A., Osborn Popp, P., Halpern, D., Rothe, A., and Gureckis, T.: Modeling Second-Language Learning from a Psychological Perspective, in *Proc. of BEA*, pp. 223–230 (2018)
- [Settles 16] Settles, B. and Meeder, B.: A Trainable Spaced Repetition Model for Language Learning, in *Proc. of ACL*, pp. 1848–1858 (2016)
- [Settles 18] Settles, B., Brust, C., Gustafson, E., Hagiwara, M., and Madnani, N.: Second Language Acquisition Modeling, in *Proc. of BEA*, pp. 56–65 (2018)
- [Shen 24] Shen, S., Liu, Q., Huang, Z., Zheng, Y., Yin, M., Wang, M., and Chen, E.: A Survey of Knowledge Tracing: Models, Variants, and Applications, *IEEE Transactions on Learning Technologies*, Vol. 17, pp. 1898–1919 (2024)
- [Vaswani 17] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., and Polosukhin, I.: Attention is All you Need, in *Proc. of NeurIPS*, pp. 5998–6008 (2017)
- [Warner 25] Warner, B., Chaffin, A., Clavié, B., Weller, O., Hallström, O., Taghadouini, S., Gallagher, A., Biswas, R., Ladhak, F., Aarsen, T., Adams, G. T., Howard, J., and Poli, I.: Smarter, Better, Faster, Longer: A Modern Bidirectional Encoder for Fast, Memory Efficient, and Long Context Finetuning and Inference, in *Proc. of ACL*, pp. 2526–2547 (2025)
- [Xu 18] Xu, S., Chen, J., and Qin, L.: CLUF: a Neural Model for Second Language Acquisition Modeling, in *Proc. of BEA*, pp. 374–380 (2018)
- [Yuan 18] Yuan, Z.: Neural Sequence Modelling for Learner Error Prediction, in *Proc. of BEA*, pp. 381–388 (2018)